

웹 OS 기반 저비용 병렬 실행 환경에서의 Computer-Use Agent 학습*)

노승혁^o, 배재영, 송지훈, 송태호, 홍지연, 장두성

서강대학교 미디어&엔터테인먼트학과, 서강대학교 컴퓨터공학과, 서강대학교 인공지능학과
{tony34036, smartjim, thdwl625, sth0119, chulsu0012, dschang}@sogang.ac.kr

Training Computer-Use Agents in a Low-Cost Parallel Execution Environment Based on Web OS

Seunghyeok Noh^o, Jaeyoung Bae, Jihun Song, Taeho Song, Jiyeon Hong, Du-Seong Chang
Sogang University, Seoul, Republic of Korea

요 약

최근 멀티모달 대규모 언어 모델의 발전으로 웹 및 데스크톱 환경에서 실제 사용자처럼 작업을 수행하는 computer-use 에이전트에 대한 관심이 증가하고 있다. 그러나 실제 운영체제 또는 VM(Virtual Machine) 기반 환경은 반복 실행 과정에서 높은 컴퓨팅 자원과 관리 비용을 요구하며, 에이전트 학습과 평가를 위해서는 반복 가능한 실행 환경과 일관된 태스크 평가 체계가 필요하다. 본 연구에서는 웹 OS 기반 저비용 병렬 실행 환경을 활용하여 태스크 정의와 성공 판정을 분리하고, 다양한 computer-use 태스크를 쉽게 추가하고 평가할 수 있도록 하였다. 이를 통해 실제 운영체제 기반 벤치마크 평가 이전 단계에서 computer-use 에이전트 실험을 위한 경량 학습 환경으로서의 가능성을 확인하였다.

1. 서 론

대규모 언어 모델의 발전은 텍스트 이해를 넘어, 실제 사용자 인터페이스를 관찰하고 조작하는 computer-use 에이전트의 가능성으로 확장되고 있다. 이러한 에이전트는 웹 탐색, 문서 편집, 파일 조작과 같은 복합적인 데스크톱 작업을 수행할 수 있어 범용 인공지능 시스템의 중요한 응용 분야로 주목받고 있다. 특히 최근에는 스크린샷, 접근성 트리, UI 상태 정보 등을 활용하여 실제 운영체제 수준의 작업 수행 능력을 평가하는 벤치마크들이 제안되고 있다 [1, 2].

그러나 실제 운영체제 또는 VM 기반 환경은 학습용 데이터 수집과 반복 실험에 여러 제약을 가진다. 환경 구성이 복잡하고 태스크마다 초기 상태를 일관되게 재현하기 어려우며, 내부 상태를 직접 점검하거나 통제하는 데에도 한계가 있다. 더 나아가 기존 VM 기반 프레임워크는 애플리케이션 구동마다 높은 비용과 컴퓨팅 자원을 요구하며, 비결정성으로 인해 통제된 반복 실험이 어렵다는 문제를 가진다.

본 연구에서는 이러한 한계를 보완하기 위해 웹 OS 기반 저비용 병렬 실행 환경에서의 computer-use 에이전트 학습을 제안한다. 이를 통해 에이전트의 태스크 수행, 자

동 평가, 반복 테스트를 하나의 흐름으로 연결하고, 태스크 정의와 성공 판정을 분리하여 다양한 computer-use 태스크를 비교적 쉽게 추가하고 평가할 수 있다.

2. 관련 연구

2.1 Computer-use 벤치마크

최근 computer-use 에이전트 연구에서는 웹 또는 데스크톱 환경에서 실제 사용자의 작업 수행 능력을 평가하기 위한 벤치마크가 활발히 제안되고 있다. 이러한 벤치마크는 스크린샷 기반 관찰, 텍스트 입력, 마우스 클릭, 스크롤, 단축키 입력 등 다양한 action space를 포함하며, 다단계 작업 수행 능력을 측정한다. 특히 운영체제 수준의 벤치마크는 단순한 웹 탐색을 넘어 창 전환, 파일 조작, 응용 프로그램 간 이동과 같은 복합적인 행위를 요구한다.

다만 이러한 벤치마크는 주로 최종 평가를 목적으로 설계되는 경우가 많아, 연구자가 새로운 태스크를 추가하거나 reward 규칙을 수정하며 반복 실험을 수행하기에는 부담이 있다. 따라서 실제 벤치마크와 유사한 상호작용 흐름을 유지하면서도, 태스크 관리와 평가 기준을 더 쉽게 제어할 수 있는 실행 계층이 필요하다.

2.2 Computer-use 에이전트 학습을 위한 실행 환경

Computer-use 에이전트 학습을 위한 실행 환경 연구는 VM 기반 full-OS 인프라와 경량 웹 기반 환경의 두 방

*) 본 연구는 2026년 과학기술정보통신부 및 정보통신기획평가원의 AI중심대학사업 지원을 받아 수행되었음(2026-0-00036)

향으로 전개되고 있다. VM 기반 접근으로는 OSGym [3]과 ComputerRL [4]이 대표적이다. OSGym은 1,000개 이상의 OS 복제본을 병렬 관리하는 확장 가능한 OS 인프라로, 데이터 수집부터 SFT(Supervised Fine-Tuning)-RL (Reinforcement Learning) 파이프라인까지 통합 지원한다. ComputerRL은 수천 개의 병렬 가상 데스크톱 환경을 통해 GLM-4-9B-0414 기반 AutoGLM-OS-9B 모델을 학습시켜 OSWorld 벤치마크에서 약 48%의 달성률을 기록했다. 그러나 이러한 접근은 에피소드마다 높은 컴퓨팅 자원과 관리 비용을 요구한다.

경량 웹 기반 접근으로는 WebGym[5]이 대표적이다. WebGym은 visual 웹 에이전트를 위한 웹 기반 상호작용 환경으로, 에이전트가 실제 웹사이트를 관찰하고 브라우저 조작을 통해 태스크를 수행하도록 구성되어 있다. 자연어 instruction, 대상 웹사이트, 평가 기준 등을 포함하며 웹 환경에서 에이전트의 관찰-행동-평가 루프를 반복 실험할 수 있다는 점에서 유용하다. 그러나 파일 조작, 창 전환, 응용 프로그램 간 이동과 같은 OS 수준의 UI 태스크를 다루기에는 범위가 제한적이다. 본 연구는 이러한 한계를 보완하여 무거운 VM 인프라 없이 OS 수준의 다양한 UI 상호작용을 반복 검증할 수 있는 경량 웹 OS 기반 실험 환경으로서의 학습 가능성을 탐색한다.

3. 학습 환경 및 태스크 구성

3.1 학습 환경

3.1.1 웹 OS

본 연구에서 웹 OS 환경은 ProzillaOS [6]를 사용했다. ProzillaOS는 창 관리, 파일 탐색기, 터미널 등 기본적인 데스크톱 구성 요소를 포함하는 오픈소스 웹 OS로, 브라우저 기반의 OS형 상호작용 환경을 구성하는 데 활용할 수 있다. 본 연구에서는 태스크 실행에 필요한 파일 조작, 텍스트 처리, 중복 이름 처리, 보호 폴더 제한, 이동 및 붙여넣기 충돌 등을 보강하여 UI 조작 결과가 내부 파일 시스템 상태와 일관되게 반영하도록 확장하였다.

3.1.2 Spreadsheet

본 연구에서는 브라우저 기반 스프레드시트 편집 기능을 제공하는 오픈소스 라이브러리인 Univer [7]에 기본 편집 UI에 에이전트 학습 및 자동 평가에 필요한 상태 조회·적용 인터페이스를 추가하여 태스크 실행 환경으로 확장하였다. 이를 통해 셀 값, 수식, 스타일, 행/열 크기 등을 세부 단위로 조회하거나 적용할 수 있도록 하였으며, 반복 가능한 초기 상태 주입과 자동 reward 계산을 통해 일관된 학습 환경을 제공한다.

3.2 Action 및 Observation 인터페이스

본 연구에서 구성한 웹 OS 기반 학습 환경 구조는 그림 1과 같다. 외부 에이전트는 세 가지 요청 타입을 통해 환경과 상호작용한다. start는 세션 초기화와 첫 스크린샷 반환을 수행하고, action은 클릭, 스크롤, 타이핑, 키 입력 등 브라우저 조작 후 observation을 반환한다. observation은 스크린샷과 a11y tree(accessibility tree)로 구성된다. 마지막으로 reward는 태스크별 평가 규칙에 따라 별도 요청으로 계산되어 평가 결과를 반환한다.




그림 1 웹 OS 학습 환경 구조

3.3 태스크 구성 및 평가

현재 태스크는 JSON 파일에 정의되며, 각 태스크는 task_id, instruction, 대상 웹사이트, evaluation 필드로 구성된다. 예를 들어 여러 숫자 데이터의 합계를 계산하여 결과 셀에 기록하는 태스크, 표의 특정 열을 기준으로 데이터를 정렬한 뒤 결과가 올바른지 검증하는 태스크 등이 포함될 수 있다.

완료 여부는 selector 존재 여부, 특정 텍스트 매칭과 같은 규칙의 조합으로 계산된다. 이 구조는 새로운 태스크를 코드 수정 없이 데이터 수준에서 추가할 수 있다는 장점을 가진다. 또한 평가 기준을 명시적으로 관리할 수 있어 태스크 수행 결과를 자동으로 판정하고, 반복 실험에서 일관된 reward를 반환할 수 있다.

4. 실험 및 결과

4.1 벤치마크 테스트

제안한 웹 OS 기반 실험 환경이 computer-use 에이전트 학습 및 평가 과정에 활용될 수 있는지 확인하기 위해, OSWorld 벤치마크의 libreoffice_calc 서브셋을 기준으로 평가를 수행했다. Qwen3.5-9B를 baseline 모델로 선정하고, 모델에 대해 학습 전후의 성능 변화를 비교하는 방식으로 수행하였다. 모델 학습에는 GRPO(Group Relative Policy Optimization)를 통한 강화학습을 적용했다. 평가 결과는 표 1과 같다.

표 1 벤치마크 점수

Model	OSWorld (%) (libreoffice_calc)
Qwen3.5-9B	14.89
Qwen3.5-9B + 제안환경에서의 강화학습	25.50

4.2 비용 비교

환경 서버와 에이전트는 분리 실행되므로, 환경의 자원 소비는 에이전트의 추론과 무관하게 동시 세션 수와 요청 빈도에 의해 결정된다. 이에 따라 AMD Ryzen 5 6600U (6C/12T, 16 GB DDR5) 로컬 머신에서 start-action-reward 요청 경로를 반복하는 방식으로 단위당 호스팅 비용을 측정하였다. 동시 세션 수를 1, 4, 8, 16, 24, 36으로 증가시키며 10분씩 실행하였으며, 요청 실패율 1% 미만이고 전체 action 요청의 95%가 완료되는 응답 시간이 단일 세션 기준 2배 이하인 최대 동시 세션 수는 24였다. 비용 환산에는 유사 사양의 Hetzner CX43(8 vCPU, 16 GB RAM, 0.0234 USD/hour)을 적용하였으며, OSGym과의 비교는 [표 2]와 같다.

표 2 환경 단위당 인프라 최소 비용 비교

구동 환경	하드웨어 환경	머신당 세션 수	머신당 일일 비용	세션당 일일 비용
OSGym	88C, DDR4 768 GB 8 vCPU,	128	29.44 USD	0.23 USD
제안 환경	DDR5 16 GB	24	0.56 USD	0.02 USD

4.3 결과 분석

표 1에서 제안 환경에 GRPO 강화학습을 적용한 이후 Qwen3.5-9B의 OSWorld 점수는 14.89%에서 25.50%로 약 10.61%p 향상되었다. 이는 제안 환경에서 학습한 상호 작용 행동이 실제 운영체제 기반 벤치마크로 전이됨을 보여준다. 한편 표 2에서 제안 환경의 세션당 일일 비용은 0.02 USD로, OSGym의 최소 비용 구성인 0.23 USD 대비 약 1/10 수준이다. 다만 OSGym은 full-OS 환경을 대상으로 하고 제안 환경은 경량 UI 태스크 실행에 한정되므로, 두 수치를 동일 선상에서 직접 비교할 수는 없다. 그럼에도 제안 환경은 VM 기반 인프라보다 현저히 작은 자원 규모로 반복 가능한 학습 환경을 제공하며, 이와 함께 학습된 행동이 실제 벤치마크 성능 향상으로 이어짐을 확인할 수 있다.

5. 결론 및 향후 연구

5.1 결론

본 연구에서는 computer-use 에이전트의 UI 기반 작업을 저비용으로 반복 학습·평가할 수 있는 웹 OS 기반 실행 환경을 제안하고 그 가능성을 확인했다. 제안 환경은 실제 OS나 VM을 직접 구동하지 않고 태스크 초기화, action 수행, observation 반환, 성공 판정을 하나의 흐름으로 연결하여 반복 가능한 실험을 지원한다. 특히 태스크 정의와 성공 판정을 분리함으로써 다양한 태스크를 코드 수정 없이 추가·검증할 수 있어, 실제 벤치마크 평가 이전 단계에서 에이전트의 행동을 점검하는 데 활용될 수 있다.

5.2 향후 연구

본 연구에서 제안한 웹 기반 학습은 저비용으로 computer-use 에이전트의 반복 실험 가능성을 확인했다는 점에서 의의가 있다. 그러나 아직 구현된 태스크의 수와 다양성이 제한적이며, 실제 OS 환경에서 나타나는 복잡한 상호작용과 장기적인 작업 흐름을 충분히 반영하지 못한다는 한계가 있다.

향후에는 더 다양한 UI 기반 태스크와 복합적인 상호작용 시나리오를 추가하여 환경의 표현 범위를 확장할 필요가 있다. 또한 본 학습 과정에서 수집한 trajectory가 실제 에이전트 성능 향상에 어떤 영향을 미치는지 정량적으로 분석함으로써, 웹 OS 기반 실행 환경의 학습 효과를 검증할 수 있을 것이다. 궁극적으로는 제안 방식이 대규모 컴퓨팅 자원이 제한된 환경에서도 computer-use 에이전트의 사전 학습과 적응 학습을 가능하게 할 것으로 기대한다.

참고문헌

- [1] Li et al., "A Survey on GUI Agents with Foundation Models Enhanced by Reinforcement Learning", arXiv:2504.20464, 2025.
- [2] Xie et al., "OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments", arXiv:2404.07972, 2024.
- [3] Qin et al., "OSGym: Scalable OS Infra for Computer Use Agents", arXiv:2511.11672, 2025.
- [4] Hanyu Lai et al., "ComputerRL: Scaling End-to-End Online Reinforcement Learning for Computer Use Agents", arXiv:2508.14040, 2025.
- [5] Bai et al., "WebGym: Scaling Training Environments for Visual Web Agents with Realistic Tasks", arXiv:2601.02439, 2026.
- [6] Prozilla, <https://github.com/prozilla-os/ProzillaOS>
- [7] Univer, <https://github.com/dream-num/univer>